

企业材料事实核验 Skill Workbench

让企业事实核验能力可运行、可评价、可解释、可发布、可回滚

火石验真官 | 高永强、高翔宇、钱旭 | <https://yet-newest-lisa-phenomenon.trycloudflare.com>

业务问题

企业尽调、产业研究和材料审核经常需要核对工商、财务、知识产权、风险与股权关系等事实。通用大模型能够读懂材料，却容易混淆同名主体、忽略年度与金额单位、把“查询不到”误判成“不存在”，也很难回答“新版本是否真的更好、出了问题能否立即恢复”。

解决方案

本项目基于公司同一个千问模型构建企业材料事实核验 Skill/Agent。用户可输入文本或上传 Markdown、TXT、CSV、Word、PDF、PPT、Excel；系统依次展示材料解析、执行轨迹和核验主张，并通过六个只读企业证据工具查询主体、工商、财务、知识产权、风险和关系数据。每条结论只能是已核实、存在冲突或证据不足，保留材料位置、证据记录和人工介入提示，不能仅凭模型记忆断言。

同条件真实复测：固定 30 条金标，通用基线准确率 23.3%，初始 Skill 90.0%，优化 Skill 100.0%；三者任务完成率和稳定性均为 100%，人工介入率分别为 80.0%、26.7%、23.3%。结果严格满足“无 Skill < 初始 Skill < 优化 Skill”。

可复现评价

三个变体使用相同数据、输入、公司模型、采样参数、工具契约、证据快照和输出结构，只改变是否加载某个冻结 Skill。汇总指标可下钻到单条输入、金标准、三个版本的原始输出和错误原因，结果由 Run Manifest 和内容哈希固定，不依赖演示者口头解释。

版本治理

Skill 从草稿、候选版到稳定版全程保留内容哈希、评测批次和版本卡。Candidate 必须通过样本量、同条件锁、准确率、完成率、稳定性、人工介入率、既有失败修复和新增硬失败八项门禁。注册后，用户仍只收到 Stable 正式答案；Candidate 在后台复制同一材料形成影子结果，经人工复核通过后才能晋升。异常时可一键回滚，历史评测和运行记录不被覆盖。

业务价值

该 MVP 不建设通用 Agent 平台，而是交付一条可验证的最小闭环：既形成可直接复用的企业事实核验能力，也沉淀评测集、报告、版本卡和发布记录，为后续 FireForge 全链路和启玄 App 的高质量能力供给提供资产。

提交资产：可运行 Agent/Skill、30 条评测集、评测报告、版本卡、影子/回滚说明及赛后 30 天计划。访问失败请联系管理员：18358585270。