

企业材料事实核验

让 Skill 能被验证、被发布，也能被安全回滚

AGENT

SKILL

MCP

EVAL

队名 **火石验真官**

成员 **高永强 · 高翔宇 · 钱旭**

AI 即岗位，结果即作品

可运行 · 可验证 · 可复制

为什么做

企业材料进入报告、招商或尽调前，必须先回答“这句话是真的吗？”

01

人工核验慢

一份材料包含多个主体、指标与风险事实，逐条查询、比对和留痕耗时。

02

通用模型会猜

模型能读懂文字，但没有企业证据时，容易把语言流畅误当成事实正确。

03

结论不可追溯

只有“对或错”还不够，业务需要知道原文位置、证据来源与人工边界。

我们要回答：材料中的事实，是 已验证、存在冲突，还是证据不足？

我们做了什么

不是让模型自由发挥，而是让 Agent 按固定 Skill 调用只读企业证据。



可信结果必须能解释

原文定位

证据 recordId

人工介入边界

一个 Agent + 一个 Skill
+ 六个只读 MCP 工具

现场演示：一条真实材料如何被核验

01 输入快照

02 执行轨迹

03 核验主张



材料原文、工具调用和结论证据同时留痕，结果可以复核。

同条件评测：只改变 Skill

同一数据集、同一输入、同一模型参数、同一工具与证据快照。

准确样本数

7/30

➡

27/30

➡

30/30

通用模型
BASELINE

初始 Skill
STABLE

优化 Skill
CANDIDATE

八项门禁同时判断

准确率 · 完成率 · 稳定性 · 人工介入率
执行成功 · 样本齐全 · 同条件 · 结果可追溯

普通使用

事实核验对话

管理控制台

演示数据

对照评测

Skill 版本

影子与发布

管理演示账号 · 未启用权限隔离

管理评测

用评测批次保留每次同条件事实，用版本汇总串联历史，用直接对比回答这一版到底改好了什么。

评测批次

按版本汇总

版本对比

查看历史结果

只读查看 · 不会重新提交 · 新到旧

2026/8/14 20:38:51

正式完整评测 (30 条) · public-tech-2024-v4 · 30 条 · 3 变体

c3ce018d

2026/8/14 20:37:21

现场快速评测 (3 条) · public-tech-live-smoke-v1 · 3 条 · 3 变体

cb6de938

发起新评测

唯一变化: 基础指令或冻结 Skill

全标数据集

现场快速评测 (3 条) · f

现场快速评测: 真实调用模型、Agent、MCP 与 ES, 但不可用于注册或发布。

稳定版 (STABLE) 版本

稳定版 (STABLE) · v0.

候选版 (CANDIDATE) 版本

请选择候选版

运行基线 (BASELINE) + 稳定版 (STABLE) + 候选版 (CANDIDATE)

同条件锁定

Run Manifest 可复现识别值

DATASET

1c84a8f165e018...

MODEL

8c7a8e3a62ac53...

PARAMS

temperature=0, topP=1, seed=2026812, parallelToolCa..., maxTokens=8192, enableThinking...

TOOLS

db7883975744de...

EVIDENCE

7dbcd576471cbe...

OUTPUT

9df97e66a832ce...

刷新评测状态

03 四项核心指标

导出报告 Markdown · 导出报告 JSON

备注	准确率 (accuracy)	任务完成率 (completionRate)	稳定性 (stability)	人工介入率 (humanInterventionRate)
基线 (BASELINE)	7/30 · 23.3%	30/30 · 100.0%	10/10 · 100.0%	24/30 · 80.0%
3d537f34-45ad-4d2f-9ebb-8a2a-3c331f6...	27/30 · 90.0%	30/30 · 100.0%	10/10 · 100.0%	8/30 · 26.7%

火石验真官 · AI 即岗位，结果即作品

05 / 07

安全发布：用户始终只看到 Stable

Candidate 在后台影子运行，同一请求双跑，但候选结果不返回给普通用户。

01

Candidate 注册

冻结内容与版本 hash

02

影子灰度

真实请求双跑、不影响用户

03

人工 PASS

查看差异与失败原因

04

晋升 / 回滚

切换 Stable 或恢复上一版

一致 1

差异 0

可回滚



赛后 30 天：沉淀为火石智能体通用能力

目标不是只交付一个 Skill，而是让任意 Skill 都具备版本、评测、灰度与回滚能力。

1-7 天

统一治理合同

版本状态、评测口径、发布边界

8-14 天

版本与评测

接入现有智能体管理端

15-21 天

通用影子灰度

真实流量观察与一键回滚

22-30 天

第二 Skill 验收

验证能力不依赖单一场景

不是只做一个 Skill，而是补齐火石智能体的 Skill 治理闭环

谢谢